



数据分析与算法设计课程大作业实验报告

实验名称	KV 查询
姓名 _	
学号_	
专业_	
院所	

2024年6月28日

目录

1	实验介绍	3
2	实验准备: 申请弹性公网 IP 和创建虚拟云	4
3	实验一: 购买 MapReduce 服务	5
4	实验二: 远程登录云服务器操作 HBase	6
5	实验三: 创建预分 region 表	13
6	实验结束: 云服务资源释放	15
7	实验总结与心得体会	15

1 实验介绍

实验简介

本课程为《大数据》实验课程,模拟高校学生系统,在华为 MRS 上进行 HBase 操作,通过创建表、对表进行 CURD 操作、创建预分 region 表及 Filter 过滤器的使用,让学员达到在 MRS 上熟练掌握 KV 查询.

实验流程

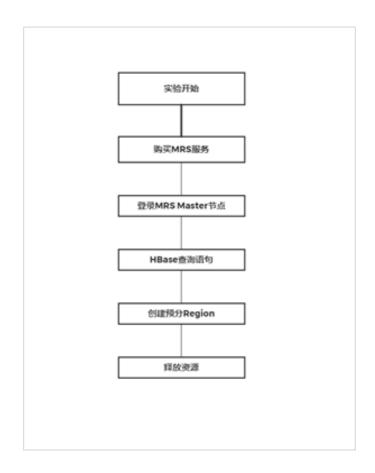


图 1: 实验流程图

实验环境

为了满足基于 HBase-MRS 实验需要,提前注册华为云账号并充值,确保通过 PUTTY 访问外网畅通。购买 MapReduce 1 个购买弹性 IP 1 个

实验准备:申请弹性公网 IP 和创建虚拟云

申请弹性公网 IP

- 1. 选择弹性公网 IP
- 2. 点击右上角的"购买弹性公网 IP"
- 3. 相关配置如图

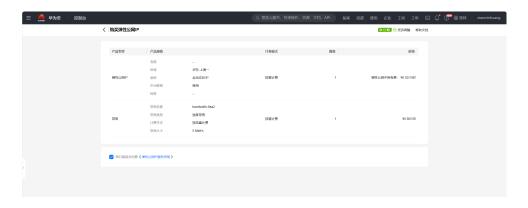


图 2: 购买弹性公网 IP

4. 查看购买的弹性公网 IP

创建虚拟云

- 1. 进入虚拟私有云控制台后,点击右上角的"创建虚拟私有云"。
- 2. 配置基本信息

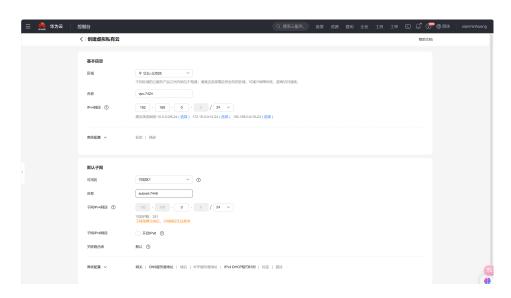


图 3: 配置虚拟云

3. 查看创建的 VPC



图 4: 查看创建的 VPC

3 实验一: 购买 MapReduce 服务

- 1. 打开 MRS 服务申请集群
- 2. 集群配置: 配置如下

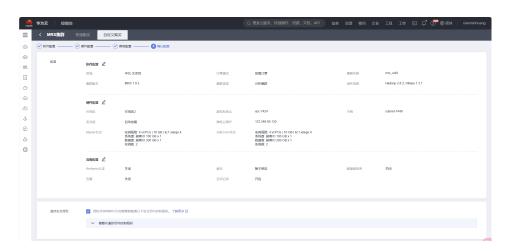


图 5: 集群配置

3. 点击集群名称,"前往 Manager"。输入用户名 admin 及密码, 点击"登录",进入 MRS Manager

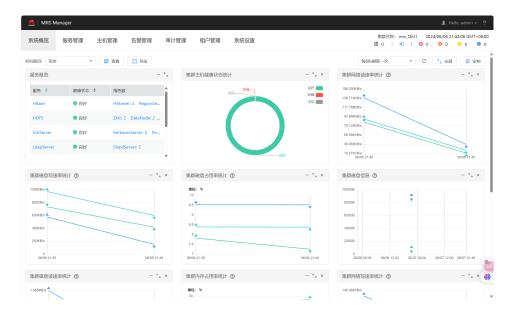


图 6: 进入 MRS Manager

4 实验二:远程登录云服务器操作 HBase

- 1. 配置安全组,选择"节点管理",点击含有"master1"的节点,在弹出页面中选择"安全组",点击"更改安全组规则",选择"入方向规则",点击"一键放通",确认即可。
- 2. 远程登录 master 节点,在安全组配置项,点击右上方"远程登录",选择 cloudshell 登录。输入密码,点击连接即可。

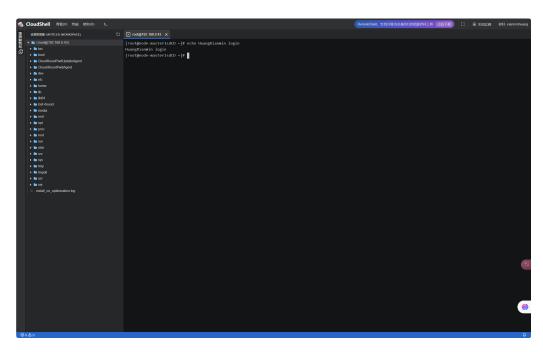


图 7: 远程连接登入

3. 设置环境变量

- # source env_file
- # hbase shell

4. 创建基表

```
# create 'cx_table_stu01', 'cf1'
```

5. list: 显示所有的表

```
# create 'cx_table_stu01', 'cf1'
```

如下图,创建了一个名为 cx_table_stu01 的空表,list 指令显示了当前有一个表 cx_table_stu01

```
hbase(main):001:0> create 'cx_table_stu01', 'cf1'
2024-06-06 21:59:18,814 INFO [main] client.HBaseAdmin: Created cx_table_stu01
0 row(s) in 1.8040 seconds

=> Hbase::Table - cx_table_stu01
hbase(main):002:0> list
TABLE
cx_table_stu01
1 row(s) in 0.0110 seconds
```

图 8: 创建和显示表

6. 增加数据

```
# put 'cx_table_stu01','20200001','cf1:name','tom'
# put 'cx_table_stu01','20200001','cf1:gender','male'
# put 'cx_table_stu01','20200001', 'cf1:age','20'
# put 'cx_table_stu01','20200002', 'cf1:name','hanmeimei'
# put 'cx_table_stu01','20200002', 'cf1:gender','female'
# put 'cx_table_stu01','20200002', 'cf1:age','19'
# scan 'cx table_stu01'
```

如下图,向表中添加了两条数据。第一条数据的 rowkey 为 20200001, 包含 name、gender、age 三个列族,第二条数据的 rowkey 为 20200002, 包含 name、gender、age 三个列族。scan 指令显示了表中的所有数据

```
=> ["cx_table_stu01"]
hbase(main):003:0> put 'cx_table_stu01','20200001','cf1:name','tom'
0 row(s) in 0.1130 seconds
hbase(main):004:0> put 'cx_table_stu01','20200001','cf1:gender','male'
0 row(s) in 0.0180 seconds
hbase(main):005:0> put 'cx_table_stu01','20200001', 'cf1:age','20'
0 row(s) in 0.0180 seconds
hbase(main):006:0> put 'cx_table_stu01','20200002', 'cf1:name','hanmeimei'
0 row(s) in 0.0140 seconds
hbase(main):007:0> put 'cx_table_stu01','20200002', 'cf1:gender','female'
0 row(s) in 0.0110 seconds
hbase(main):008:0> put 'cx_table_stu01','20200002', 'cf1:age','19'
0 row(s) in 0.0160 seconds
```

图 9: 向表中添加数据

7. Scan 方式查询数据

```
# scan 'cx_table_stu01',{COLUMNS=>'cf1'}
# scan 'cx_table_stu01',{COLUMNS=>'cf1:name'}
```

如下图, scan 指令可以查询表中的所有数据,也可以指定列族查询数据

```
hbase(main):004:0> scan 'cx table stu01'
20200001
                                                  column=cf1:age, timestamp=1717682416029, value=20
20200001
20200001
                                                  column=cf1:name, timestamp=1717682377264, value=tom
20200002
20200002
                                                  column=cf1:name, timestamp=1717682420717, value=hanmeimei
hbase(main):005:0> scan 'cx_table_stu01',{COLUMNS=>'cf1'}
                                                 COLUMN+CELL
                                                  column=cf1:age, timestamp=1717682416029, value=20
20200001
20200001
20200002
                                                 column=cf1:gender, timestamp=1717682426300, value=female
column=cf1:name, timestamp=1717682420717, value=hanmeimei
20200002
2 row(s) in 0.0230 seconds
hbase(main):006:0> scan 'cx_table_stu01',{COLUMNS=>'cf1:name'}
                                                 COLUMN+CELL
20200001
20200002
                                                  column=cf1:name, timestamp=1717682420717, value=hanmeimei
```

图 10: scan 查询数据结果

8. Get 方式查询数据

```
# get 'cx_table_stu01','20200001'
# get 'cx_table_stu01','20200001','cf1:name'
```

9. 指定条件查询数据

```
# scan 'cx_table_stu01',{STARTROW=>'20200001','LIMIT'=>2,STOPROW=>'20200002'}
```

如下图, get 指令可以查询指定 rowkey 的数据,也可以指定列族查询数据。scan 指令可以指定条件查询数据,可以指定起始行、终止行、查询条数等条件

```
hbase(main):007:0> get 'cx_table_stu01','20200001'
                                              timestamp=1717682416029, value=20
                                              timestamp=1717682385876, value=male
cf1:name
                                              timestamp=1717682377264, value=tom
hbase(main):008:0> get 'cx_table_stu01','20200001','cf1:name'
COLUMN
                                              timestamp=1717682377264, value=tom
1 row(s) in 0.0200 seconds
hbase(main):009:0> scan 'cx_table_stu01',{STARTROW=>'20200001','LIMIT'=>2,STOPROW=>'20200002'}
                                             COLUMN+CELL
 20200001
                                              column=cf1:age, timestamp=1717682416029, value=20
 20200001
                                             column=cf1:gender, timestamp=1717682385876, value=male
                                             column=cf1:name, timestamp=1717682377264, value=tom
 20200001
```

图 11: get 与指定条件查询数据结果

10. 过滤器查询

如下图,过滤器查询可以通过指定条件查询数据,可以通过值、列族、列名等条件 查询数据

图 12: 过滤器查询结果

11. 查询多版本数据,Hbase 可以存储历史版本的数据,通过设定版本号 VERSIONS 值,版本号为几就是存储几个版本。

增加数据执行命令:

```
# put 'cx_table_stu01','20200001','cf1:name','ZhangSan'

# put 'cx_table_stu01','20200001','cf1:name','LiSi'

# put 'cx_table_stu01','20200001','cf1:name','WangWu'

然后get时指定多版本查询:

# get 'cx table stu01','20200001',{COLUMNS=>'cf1',VERSIONS=>5}
```

如下图,添加不同版本的数据,然后查询多版本数据,可以看到 get 指令只查询了 20200001 版本的数据

图 13: 多版本查询

12. 查看表的属性, 执行语句:

#desc 'cx_table_stu01'

如下图,可以看到表的属性,包括表名、列族、版本数等信息

```
Dbase(main):013:0> desc 'cx_table_stu01'
Table cx_table_stu01 is ENABLED
cx_table_stu01 is ENABLED
cx_table_stu01 is ENABLED
cx_table_stu01
COLUMN FANILIES DESCRIPTION
(NAME => 'rou', DLOMFILTER >> 'ROu', VERSIONS => '1', IN_MEMORY -> 'false', KEEP_DELETED_CELLS => 'FALSE', DATA_BLOCK_ENCODING -> 'NOME', TTL -> 'FOREVER', COMPRESSION -> 'NOME'
, MIN_VERSIONS -> '0', BLOCKCACHE => 'true', BLOCKSIZE => '65536', REPLICATION_SCOPE => '0')
1 row(s) in 0.3760 seconds
```

图 14: 表属性查看

13. 查看多个版本的数据: 需要修改表的 VERSIONS 值(或者在建表的时候就指定 VERSIONS 值)

```
# alter 'cx_table_stu01',{NAME=>'cf1','VERSIONS'=>5}
# put 'cx_table_stu01','20200001','cf1:name','ZhangSan'
# put 'cx_table_stu01','20200001','cf1:name','LiSi'
# put 'cx_table_stu01','20200001','cf1:name','WangWu'
# get 'cx_table_stu01','20200001',{COLUMN=>'cf1',VERSIONS=>5}
```

alter 指令可以修改表的属性,包括列族、版本数等信息。如下图,修改了表的版本数为 5,然后添加了不同版本的数据,查询多版本数据,可以看到 get 指令查询了 20200001 版本的数据

```
hbase(main):014:0> alter 'cx_table_stu01',{NAME=>'cf1','VERSIONS'=>5}
Updating all regions with the new schema...
0/1 regions updated.
0 row(s) in 2.9280 seconds
hbase(main):015:0> put 'cx_table_stu01','20200001','cf1:name','ZhangSan'
 row(s) in 0.0170 seconds
hbase(main):016:0> put 'cx_table_stu01','20200001','cf1:name','LiSi'
0 row(s) in 0.0240 seconds
hbase(main):017:0> put 'cx table stu01','20200001','cf1:name','WangWu'
hbase(main):018:0> get 'cx_table_stu01','20200001',{COLUMN=>'cf1',VERSIONS=>5}
COLUMN
cf1:age
                                              timestamp=1717682416029, value=20
 cf1:gender
                                              timestamp=1717684364142, value=WangWu
                                              timestamp=1717684358740, value=LiSi
                                              timestamp=1717684350661, value=ZhangSan
 cf1:name
                                              timestamp=1717683734351, value=WangWu
 row(s) in 0.0170 second
```

图 15: 多版本数据查询

14. 删除数据

```
删除某列族下数据,执行命令:

# delete 'cx_table_stu01','20200002','cf1:age'
# get 'cx_table_stu01','20200002'

删除整行数据,执行命令:

# deleteall 'cx_table_stu01','20200002'

# get 'cx_table_stu01','20200002'
```

```
hbase(main):001:0> get 'cx_table_stu01','20200002
COLUMN
cf1:age
                                              timestamp=1717682430541, value=19
 cf1:gender
                                              timestamp=1717682426300, value=female
 cf1:name
                                              timestamp=1717682420717, value=hanmeimei
1 row(s) in 0.3560 seconds
hbase(main):002:0> delete 'cx_table_stu01','20200002','cf1:age'
0 row(s) in 0.0590 seconds
hbase(main):003:0> get 'cx_table_stu01','20200002'
COLUMN
 cf1:gender
                                              timestamp=1717682426300, value=female
 cf1:name
                                              timestamp=1717682420717, value=hanmeimei
 row(s) in 0.0100 seconds
```

图 16: 删除表中数据

15. 删除表

```
用drop命令可以删除表。但是在删除一个表之前必须先将其禁用。
第一步: disable "表名称"
# disable 'cx_table_stu01'
第二步: drop "表名称"
```

drop 'cx_table_stu01'

```
hbase(main):002:0> disable 'cx_table_stu01'

2024-06-06 22:40:40,952 INFO [main] client.HBaseAdmin: Started disable of cx_table_stu01

2024-06-06 22:40:43,190 INFO [main] client.HBaseAdmin: Disabled cx_table_stu01

0 row(s) in 2.3500 seconds

hbase(main):003:0> drop 'cx_table_stu01'

2024-06-06 22:40:54,032 INFO [main] client.HBaseAdmin: Deleted cx_table_stu01

0 row(s) in 1.2400 seconds

hbase(main):004:0> list

TABLE

0 row(s) in 0.0160 seconds
```

图 17: 删除表

5 实验三: 创建预分 region 表

HBase 默认建表时只有一个 region,这个 region 的 rowkey 是没有边界的,即没有 startkey,也没有 endkey。在数据写入时,所有数据都会写入这个默认的 region,随着数据量的不断增加,此 region 已经不能承受不断增长的数据量,会进行 split,分成 2 个 region。在此过程中,会产生两个问题:

- 1. 数据往一个 region 上写, 会有写热点问题。
- 2. region split 会消耗宝贵的集群 I/O 资源。

基于此我们可以在建表的时候,创建多个空 region,并确定每个 region 的起始和终止 rowky,这样只要我们的 rowkey 设计能均匀的命中各个 region,就不会存在写热点问题,自然 split 的几率也会大大降低。hbase 提供了两种 pre-split 算法: HexStringSplit 和 UniformSplit,前者适用于十六进制字符的 rowkey,后者适用于随机字节数组的 rowkey。以 rowkey 切分,随机分为 4 个 region。以 rowkey 切分,随机分为 4 个 region。

1. 创建表执行命令:

create 'cx_table_stu02','cf2',{NUMREGIONS => 4,SPLITALGO =>'UniformSplit'}
Region命名格式: [table],[region start key],[region id]

```
hbase(main):005:0> create 'cx_table_stu02','cf2',{NUMREGIONS => 4,SPLITALGO =>'UniformSplit'}
2024-06-06 22:45:29,941 INFO [main] client.HBaseAdmin: Created cx_table_stu02
0 row(s) in 1.2680 seconds
=> Hbase::Table - cx_table_stu02
hbase(main):006:0>
```

图 18: 创建表

2. 登录 HBase WebUI 查看表的分区情况 MRS Manager 界面,点击"HBase"服务,点击 HMaster(主)进入 HBase UI,"User Tables"下点击创建好的表名"cxtablestu02"

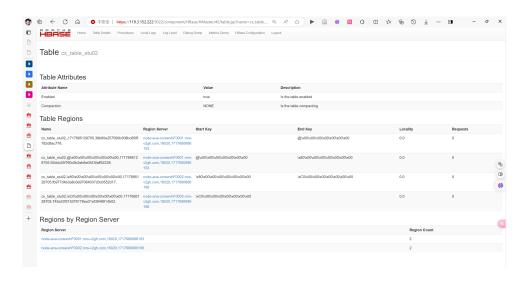


图 19: 查看该表分区情况

3. 指定 region 的 startKey 和 endKey

创建表执行命令:

create 'cx_table_stu03', 'cf3', SPLITS => ['10000', '20000', '30000']

```
hbase(main):001:0> create 'cx_table_stu03', 'cf3', SPLITS => ['10000', '20000', '30000']
2024-06-06 22:54:23,820 INFO [main] client.HBaseAdmin: Created cx_table_stu03
0 row(s) in 1.5990 seconds
=> Hbase::Table - cx_table_stu03
hbase(main):002:0>
```

图 20: 创建表

同理,查看该表分区情况:

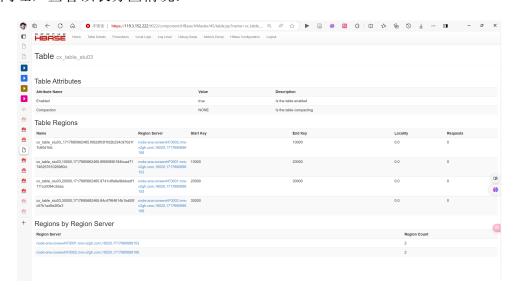


图 21: 查看该表分区情况

6 实验结束:云服务资源释放

释放 MapReduce 服务

1. 进入 MRS 控制台,点击集群后的删除按钮

释放网络资源 VPC

- 1. 进入 VPC 控制台界面
- 2. 删除 IP: 点击"弹性公网 IP 和带宽",选择弹性公网 IP,选中所有 IP,点击释放按钮.
- 3. 删除安全组规则:点击"访问控制",选择安全组,点击安全组名称,选择入方向规则,点击列表后的删除按钮。

7 实验总结与心得体会

在这次 KV 查询实验中,我通过模拟高校学生系统,在华为 MRS 平台上进行了 HBase 操作,主要包括创建表、CURD 操作、创建预分 region 表及使用 Filter 过滤器 等内容。整个实验过程让我深刻理解了 HBase 的基础操作以及在实际应用中的重要性。

首先,实验准备阶段,我体验了从申请弹性公网 IP 到创建虚拟私有云的完整过程。 在此过程中,我通过华为云控制台完成了相关配置,成功购买了弹性公网 IP 和虚拟私 有云。这不仅让我熟悉了华为云平台的操作,也让我认识到在大数据处理环境中,网络 资源的配置和管理是基础且关键的一步。通过这一过程,我深刻体会到了云计算资源的 灵活性和便捷性,同时也学会了如何高效地管理和使用这些资源。

在购买 MapReduce 服务并配置集群时,我进一步加深了对大数据处理框架的理解。通过配置集群并进入 MRS Manager,我了解了集群管理的基本操作。这一步骤让我认识到,合理配置和管理集群对于大数据处理的效率和性能至关重要。在实际操作中,我学会了如何根据实验要求配置集群参数,以及如何通过 MRS Manager 进行集群管理和监控。

实验二的重点是远程登录云服务器并进行 HBase 操作。这部分内容让我对 HBase 的基本操作有了全面的了解。从配置安全组、远程登录 master 节点到设置环境变量,再到创建表、增加数据、查询数据、删除数据等一系列操作,每一步都让我对 HBase 的工作原理有了更深入的理解。例如,通过创建一个简单的表并向其中添加数据,我体会到了 HBase 在处理大规模数据时的高效性和灵活性。此外,通过使用不同的查询命令(如 scan 和 get),我学会了如何根据具体需求灵活查询数据。而在使用过滤器进行数据查询时,我认识到了 HBase 在数据过滤和查询方面的强大功能,这对于实际应用中快速定位和提取数据非常有帮助。

实验三中创建预分 region 表的操作让我认识到在大数据处理过程中如何避免写热点问题。通过预先定义多个 region 并设置 rowkey 的起始和终止值,我们可以有效分散数据写入的压力,避免单一 region 过载问题。这不仅提高了数据写入的效率,也减少了 region split 对集群资源的消耗。通过这一操作,我深刻体会到在实际应用中,合理设计和管理数据存储结构对于提高系统性能至关重要。

在实验过程中遇到的一些问题和挑战也让我受益匪浅。例如,在配置虚拟私有云时,由于对华为云平台的操作不够熟悉,我曾一度在网络配置上遇到困难。但通过查阅相关资料并不断尝试,我最终解决了这些问题。这不仅增强了我的问题解决能力,也让我对华为云平台有了更深入的了解。

此外,在操作 HBase 时,由于对 HBase 的命令不够熟悉,我曾在数据查询和过滤器使用上遇到了一些问题。但通过反复练习和实验,我逐渐掌握了这些命令的使用方法。这让我认识到,在学习和掌握新技术时,动手实践和反复操作是非常重要的。

通过这次实验,我不仅掌握了 HBase 的基本操作和使用技巧,也对大数据处理的整个流程有了更全面的理解。从申请和配置云资源,到管理和操作 HBase,再到解决实际操作中遇到的问题,每一步都让我受益匪浅。这些知识和技能不仅对我今后的学习和工作非常有帮助,也让我对大数据处理技术充满了兴趣和信心。

总的来说,这次 KV 查询实验不仅让我掌握了许多实用的技能,也让我对大数据处理技术有了更深刻的理解和认识。在未来的学习和工作中,我将继续深入学习和探索大数据处理技术,不断提升自己的专业能力和水平。通过这次实验,我深刻体会到,只有不断实践和总结,才能真正掌握和运用所学的知识,实现自己的职业目标和价值。